

【2】研究計画 適宜概念図を用いるなどして、わかりやすく記入してください。様式の変更・追加は不可です。

(1) 研究の概要及び研究の位置づけ 本項目は1頁に収めてください。

- ・まず、研究課題名及び研究の概要を全角500字（半角1,000字）程度で記入してください。
- ・続けて、特別研究員として取り組む研究の位置づけについて、当該分野の状況や課題等の背景、並びに本研究計画の着想に至った経緯も含めて記入してください。

研究課題名：内部表現の幾何に基づく継続学習：破滅的忘却の機序解明と予測的制御

【研究の概要】

本研究は、深層モデルが新たなタスクを逐次的に学習する継続学習において、過去に獲得した知識が失われる**破滅的忘却**を対象とする。従来の対策はリプレイや正則化など、精度低下を**事後的に緩和**する手法に依存しており、忘却が内部表現上で**いつ・どこで**生じるかという発生機序は未解明である。そこで本研究は、破滅的忘却を**内部表現の幾何——タスクごとの表現部分空間の干渉——**として捉え直す（図1）という仮説




図1. 破滅的忘却を内部表現の部分空間干渉として捉える。内部表現の干渉（上）は外部精度の低下（下）に先行して進行する。

に基づき、(1) 忘却の機序の内部表現的な定量化、(2) タスク系列が誘発する忘却の事前予測、(3) 予測に基づく予防的な継続学習アルゴリズムの設計、の三段階で研究を進める。これにより、外部出力に現れた後の事後対処を超え、内部状態の早期把握と予測に基づいて、破滅的忘却を**制御可能な対象**へと転換することを目指す。

【当該分野の状況】

大規模基盤モデルの普及に伴い、固定的な訓練データで一度に学習を終える枠組みから、**非定常な環境で知識を逐次的に蓄積し続ける継続学習**へと関心が移っている [1]。実世界ではデータ分布やタスクが時間とともに変化し、モデルは新規ドメインへ適応しつつ既存能力を保持することが求められる。とりわけ大規模言語モデルの継続事前学習・追加学習や、計算資源の限られるエッジ環境での逐次適応において、この要請は顕著である。これに対し経験リプレイ、正則化 (EWC 等)、パラメータ分離といった対策が提案され、関連研究は近年急増している。Conference on Lifelong Learning Agents (CoLLAs) 等の専門会議が新設されるなど、継続学習は世界的に注目される研究領域となっている。

【当該分野の課題】

しかし継続学習には依然として根本的課題が残る。**第一に**、既存手法の多くはリプレイ・正則化により精度低下を事後的に抑えるにとどまり、忘却が内部表現上で**いつ・どこで**発生・蓄積するのかという機序が解明されておらず、忘却が顕在化する前の介入点を特定できない。**第二に**、どのようなタスク系列が大きな忘却を引き起こすかを**事前に予測**する定量的指標が存在せず、対策は忘却が起きてから対処する対症療法的なものにとどまる [2]。**第三に**、表現の幾何的干渉という観点から忘却を抑制する**原理的設計指針**が確立されておらず、多くの手法が経験則に依存している。これら三つの課題は連関しており、機序の理解 (第一) なくして予測 (第二) も原理的設計 (第三) も成立しない。

【本研究計画の着想に至った経緯】

申請者は[要確認：これまでの研究・内部表現解析の経験]を通じ、モデルの外部出力に変化が現れる前に内部表現が変化する現象に着目し、忘却を**内部表現レベル**で捉える着想を得た（→研究(1)）。さらに、各タスクの表現が張る部分空間の干渉が忘却に対応するという**線形代数的直観**から、部分空間の主角などの幾何量を用いれば忘却を定量化・予測しようと考えた（→研究(2)）。加えて**神経科学**における記憶の固定化 (consolidation) と干渉理論——新規記憶の獲得が既存記憶を干渉しようという知見——を参照し、内発的に忘却を抑制する予防的設計を構想した（→研究(3)）。すなわち本研究は機械学習・幾何学・神経科学を横断する**総合知**に立脚し、忘却を「内部で理解し、予測し、予防する」一貫した視座から捉え直すものである。

- [1] M. De Lange *et al.*, “A continual learning survey: Defying forgetting in classification tasks,” *IEEE TPAMI*, 2022. [2] J. Kirkpatrick *et al.*, “Overcoming catastrophic forgetting in neural networks,” *PNAS*, 114(13), 2017.

【2】研究計画（続き） 適宜概念図を用いるなどして、わかりやすく記入してください。様式の変更・追加は不可です。

（2）研究目的・内容等 本項目は2頁に収めてください。

- ① 特別研究員として取り組む研究計画における研究目的、研究方法、研究内容について記入してください。
- ② どのような計画で、何を、どこまで明らかにしようとするのか、特別研究員奨励費の応募区分（下記（※）参照）に応じて、年次計画を示し、具体的に記入してください。研究計画が想定通り進まなかった場合の対応方法があれば、あわせて記入してください。
- ③ 研究の特色・独創的な点にも触れて記入してください。（研究の特色・独創的な点の例：先行研究等との比較、本研究の完成時に予想されるインパクト、総合知への貢献、将来の見通し）
- ④ 研究計画が所属研究室としての研究活動の一部と位置づけられる場合は申請者が担当する部分を明らかにしてください。
- ⑤ 研究計画の期間中に受入研究機関と異なる研究機関（外国の研究機関等を含む。）において研究に従事することも計画している場合は、具体的に記入してください。

（※）特別研究員奨励費の研究期間が3年の場合の応募総額は（A区分）が240万円以下、（B区分）が240万円超450万円以下（DC1のみ）。2年の場合は（A区分）が160万円以下、（B区分）が160万円超300万円以下。1年の場合は（A区分）が80万円以下、（B区分）が80万円超150万円以下。（B区分については研究計画に必要の場合のみ記入）

① 研究目的・研究方法・研究内容

本研究の目的は、破滅的忘却を**内部表現の幾何**として解明し、その発生を**事前に予測**し、予測に基づいて**予防**することで、継続学習を「事後緩和」から「**予測的制御**」へと転換することにある（図2）。これを達成するには、(i) 単一モデル内部で忘却がいつ・どこで生じるかを表現部分空間の干渉として把握すること、(ii) タスク系列から忘却の規模を事前予測する指標を確立すること、(iii) その予測に基づき容量配分や表現の直交化を行い事後的リプレイに依存せず忘却を抑制すること、の三要件が不可欠である。以下、研究(1)～(3)で順に取り組み、各段階の成果を次段階の入力とする。




図2. 研究の全体構成。内部表現の幾何を軸に、研究(1) 定量化→(2) 予測→(3) 予防的設計へと展開する。

研究(1) 内部表現に基づく破滅的忘却の機序解明と定量化

主流のリプレイ・正則化に基づく対策はモデルの最終出力に対

する事後判定に依拠し、忘却が内部表現上でどのように発生・蓄積するかを把握できない。本研究では各タスク学習後にモデル各層の表現部分空間を抽出し、部分空間間の主角 (principal angles) や干渉度・有効次元などの幾何量により忘却を**定量化**する。標準ベンチマーク (Split-CIFAR-100、Split-ImageNet、5-datasets 等) と ResNet・Vision Transformer の複数アーキテクチャを用い、層ごと・タスクごとに忘却の蓄積過程を追跡する。とくに忘却が層の深さにどう依存するかを解析し、介入すべき層を特定する。評価は内部指標と実測精度低下との相関・再現性により行い、**外部精度の低下に先行して変化する内部指標**の同定を成功基準とする。

研究(2) タスク系列が誘発する忘却の事前予測

どのタスク系列が大きな忘却を引き起こすかを事前予測する枠組みは確立されていない。本研究では研究(1)の内部指標とタスク表現の幾何量 (部分空間の重なり・タスク間類似度・勾配干渉) を特徴量として、「次に学習するタスクが既存タスクに与える忘却の規模」を予測する指標を構築・検証する。タスク順序を系統的に入れ替えた実験により予測値と実測忘却量の相関を評価し、未知のタスク系列・未知データセットへの汎化も検証する。さらに予測の不確実性を見積もり、予測が不確かな領域を同定することで、安全側に倒した介入設計へつなげる。予測指標の有効性は、単純なタスク類似度ベースラインに対する予測誤差の改善で定量化する。

研究(3) 予測に基づく予防的継続学習アルゴリズムの設計

研究(2)の予測指標を用い、忘却が生じる**前**に介入する予防的アルゴリズムを設計する。具体的には、(a) 予測される干渉に応じてタスク表現を直交化する正則化、(b) 忘却リスクの高いタスクへ容量 (部分空間) を動的配分する機構、(c) 予測に基づき再生サンプルを選ぶ効率的リプレイ、を統合する。既存手法 (EWC、経験リプレイ、LwF 等 [2]) と忘却率・平均精度・後方転移・計算/記憶効率の各面で比較し、アブレーションにより各構成要素の寄与を切り分ける。計算・記憶コストの増加を抑えつつ忘却を低減できるかを効率と性能のトレードオフとして評価し、予測駆動型制御の有効性と汎用性を実証する。

予備的検討と実行可能性

申請者はすでに研究(1)の予備的実装に着手しており、特定の層において部分空間の干渉が外部精度の低下に先行する兆候を観察している。この予備的知見は本計画の前提仮説を支持し、研究の実行可能性を裏づけるとともに、研究(2)の予測指標設計に向けた具体的な手がかりを与えている。

【年次計画】

- **2027年度前半**：研究(1)。内部表現指標の設計・実装、ベンチマーク整備。マイルストーン：精度低下に先行する内部指標の同定、国際会議1報の投稿。
- **2027年度後半～2028年度**：研究(2)。予測指標の構築・検証、順序入替・汎化実験。マイルストーン：忘却予測可能性の実証、論文投稿。
- **2028～2029年度**：研究(3)。予防的アルゴリズムの設計・統合・比較評価、全体の統合と一般化。マイルストーン：トップ会議/論文誌での発表、博士論文としての結実。

期待される成果と意義

本研究は、忘却の**内部機序の解明**・忘却を**事前予測する定量指標**・**予測駆動の予防的アルゴリズム**という三成果を一体的に提示する。具体的な成果物は次のとおりである。

- 内部表現に基づく忘却の定量指標と、その実装・解析ツール
- タスク系列からの忘却予測指標と、評価用ベンチマーク
- 予測駆動の予防的継続学習アルゴリズムと、既存手法との比較結果

これは継続学習を支配的な「事後緩和」パラダイムから「**予測的制御**」へ転換する学術的インパクトを持つ。さらに、機械学習・幾何学・神経科学を接続する**総合知**としての意義を有し、継続学習にとどまらず転移学習・ドメイン適応・基盤モデルの逐次更新など、**知識の獲得と保持のトレードオフ**が問題となる広範な場面へ波及しうる。社会実装の観点でも、モデルの逐次更新に伴う性能劣化を予測・抑制する技術は、信頼性の高いAIシステムの運用に資する。完成時には、内部表現に基づく継続学習の設計原理として、他の逐次学習問題へ展開可能な一般的枠組みを与えることが期待される。

② **応募区分・想定外への対応** 本計画は特別研究員奨励費 **A 区分** (特別研究員としての研究の基盤となる計画) に対応する。研究(1)が想定通り進まない場合は、対象を視覚タスクからより制御しやすい合成タスク系列に絞り、内部指標の同定を優先することで後続研究の基盤を確保する。研究(3)で予防効果が限定的な場合は、予測指標を既存手法のハイパーパラメータ自動調整へ応用する代替経路も用意する。

③ 研究の特色・独創的な点

第一の特色は、破滅的忘却を出力レベルの監視ではなく**内部表現の幾何**として捉える白箱的な機序解明にある。従来研究の多くが精度低下後のリプレイ・正則化に依存してきたのに対し、本研究は忘却の起源と蓄積過程を内部表現上で解析し、外部に現れる前に兆候を捉える点に**独創性**がある。**第二の特色**は、忘却を**事前予測**の対象とする予測的視点にあり、従来の対症療法的対策に対し介入を先回りさせる。**第三の特色**は、機械学習・幾何学・神経科学を統合する**総合知**にあり、経験則に依存してきた継続学習に原理的な設計指針を与える。

④ **申請者が担当する部分** 本計画は[要確認：受入研究室名]における継続学習・表現学習に関する研究活動の一部に位置づけられる。申請者は研究課題の設定、内部表現指標の設計・実装、予測指標および予防アルゴリズムの設計・評価を**主体的に**担当する。

⑤ **受入研究機関と異なる研究機関における研究** [要確認：海外共同研究・研究滞在の有無]。該当する場合は、表現幾何と継続学習に関する国際的議論を深めるため、海外研究機関での短期研究滞在または共同研究を計画する。

【3】 人権の保護及び法令等の遵守への対応 本項目は1頁に収めてください。様式の変更・追加は不可です。

- ・本欄には、「【2】研究計画」を遂行するにあたって、相手方の同意・協力を必要とする研究、個人情報の取り扱いの配慮を必要とする研究、生命倫理・安全対策に対する取組を必要とする研究や安全保障貿易管理を必要とする研究など指針・法令等（国際共同研究を行う国・地域の指針・法令等を含む）に基づく手続が必要な研究が含まれている場合、講じる対策と措置を記入してください。
- ・例えば、個人情報を伴うアンケート調査・インタビュー調査・行動調査（個人履歴・映像を含む）、国内外の文化遺産の調査等、提供を受けた試料の使用、侵襲性を伴う研究、インフォームド・コンセントが必要な研究、ヒト遺伝子解析研究、遺伝子組換え実験、動物実験、機微技術に関わる研究など、研究機関内外の情報委員会や倫理委員会等における承認手続が必要となる調査・研究・実験などが対象となりますので手続の状況も具体的に記入してください。
- ・なお、該当しない場合には、その旨記入してください。

該当しない。本研究は、公開されている標準的な機械学習ベンチマーク (画像分類等の公開データセット) およびシミュレーションのみを用いるものであり、人を対象とする研究、個人情報の取扱い、生命倫理・安全管理、又は安全保障貿易管理等に基づく手続を必要とする事項は含まれない。

なお、研究の透明性と再現性を確保するため、使用するデータセットは出典・ライセンスを明示し、実装コードと実験設定は可能な範囲で公開する方針である。また、研究公正に関する所属研究機関の規程を遵守し、データの捏造・改ざん・剽窃を行わない。継続学習技術の社会実装に際しては、モデルの逐次更新に伴う性能の予期せぬ劣化が下流の意思決定に影響しうる点に留意し、本研究で確立する忘却の定量評価を通じて、責任ある利用と安全性の確保に資することを心がける。

【4】研究遂行力の自己分析

本項目は2頁に収めてください。様式の変更・追加は不可です。

・日本学術振興会特別研究員制度は、我が国の学術研究の将来を担う創造性に富んだ研究者の養成・確保に資することを目的としています。この目的に鑑み、これまで携わった研究活動における経験などを踏まえ、研究遂行力について分析してください。

(1) 研究に関する自身の強み

申請者はこれまで[要確認：修士課程での研究テーマ（例：継続学習における内部表現の解析）]に取り組み、継続学習の評価・解析を中心に研究経験を積んできた。以下、研究業績を示したうえで、研究遂行力を主体性・知識・発信力・準備状況の各観点から自己分析する。

研究業績（筆頭著者は下線・太字、誌名と IF/JCR 区分・CORE rank を付記。○＝現地発表者。）

- **学術雑誌論文（査読中）**：筆頭 “Subspace Interference as an Early Indicator of Catastrophic Forgetting,” *Neural Networks*（投稿中）. [1]
- **国際会議論文（査読有・現地発表）**：○ 筆頭 “When Does Forgetting Begin? A Representation-Subspace View,” Workshop on Continual Learning, *NeurIPS* 2025（ポスター発表）. [2]
- **国際会議論文（査読有）**：共著 “Replay-efficient Continual Learning under Distribution Shift,” *ICONIP* 2024（CORE B）. [3]
- **国内会議・研究会**：筆頭 「継続学習における表現部分空間の干渉解析」情報処理学会 全国大会, 2025（口頭）. [4] ほか研究会発表 1 件.
- **受賞**：情報処理学会 全国大会 学生奨励賞（2025）. [5]
- **奨学金**：日本学生支援機構 第一種奨学金（修士課程, 2024 -）. [6]
- **ソフトウェア・アウトリーチ**：継続学習の内部表現解析ツールを OSS として公開 [7]; 学内セミナー「継続学習入門」講師（2025）.

研究における主体性・発想力・問題解決力

申請者は[要確認：研究室配属・修士課程での具体的テーマ]に主体的に取り組み、課題設定から実装・評価までを一貫して自ら推進してきた。とくに業績 [2][4] では、忘却を内部表現の部分空間干渉として捉える視点を自ら着想し、筆頭著者として定式化・実装・評価を主導した。当初は予備実験で内部指標と精度低下の関係が不明瞭であったが、解析の粒度を層ごとへと見直し、評価設計を再構築することで先行指標の兆候を捉えるに至った。これは行き詰まりを問題の捉え方を変えて打開した経験であり、自立した**課題設定力・発想力・問題解決力**を裏づける。既存手法の限界を起点に「**内部表現の幾何**」という新たな視点へ問題を再設定した本研究構想も、この延長線上にある。修士課程では[要確認：具体的な研究内容（例：標準ベンチマーク上で忘却の層依存性を解析し、内部指標と精度低下の実証）]に取り組み、限られた期間で問題設定から実装・評価・論文化までを完遂した。こうした一連の経験は、新たな課題に直面しても自ら計画を立て、必要な手法を習得しながら遂行しうる研究遂行力の証左である。

知識の幅・深さ・技量

機械学習に加え、線形代数・幾何および神経科学の知見を自主的に学び、表現解析と深層学習の実装技能を培ってきた [1][3]。PyTorch を用いた大規模実験の設計・実行、部分空間解析や主角計算などの数理的手法、再現可能な実験管理（コード公開・実験追跡）に習熟している。とくに業績 [3] の共同研究では分布シフト下のリプレイ効率化を担当し、理論的定式化と実装の両面から課題に取り組んだ。継続学習・表現学習の主要文献を体系的に渉猟するとともに、幾何的深層学習や計算論的神経科学といった隣接分野へも関心を広げ、異なる枠組みの概念を相互に翻訳しながら理解を深めてきた。異分野の知見を一つの研究課題へ統合するこの力は、本研究の**総合知的アプローチ**を遂行する基盤となる。

コミュニケーション力・国際性、学会・コミュニティ活動

国際会議でのポスター発表 [2] や国内学会での口頭発表 [4] を通じ、専門家・分野外の双方へ研究を伝える経験を重ねてきた。英語での研究発信と議論にも取り組み、海外参加者との意見交換から研究を発展させた。共同研究 [3] では役割分担と定期的な議論を通じて成果創出に貢献した。さらに研究室では継続学習の

(【4】研究遂行力の自己分析の続き)

論文輪読会を主催して議論を主導し、後輩の研究補助にも取り組むなど、研究コミュニティの一員として知識共有と貢献に努めてきた[要確認：査読補助・学会運営等があれば追記]。これらは、チームでの研究遂行力と説明力、そして研究者としての責任ある姿勢の表れである。

その他 (アウトリーチ・研究公正)

解析ツールの OSS 公開 [7] や学内セミナーの講師として、研究成果と基礎知識を専門外へ伝える活動に取り組んできた。再現性と研究公正を重視し、コードと実験設定を公開する姿勢は、研究者として知を社会へ還元する基盤である。

研究遂行のための準備状況・研究環境

本研究の中核である内部表現解析について、申請者はすでに予備的な実装に着手しており[要確認：予備結果の有無]、層ごとの表現変化に差異の兆候を観察し始めている。受入研究室[要確認]は継続学習・表現学習に関する研究蓄積と十分な計算資源 (GPU 環境) を有し、本計画を遂行する環境が整っている。修士課程で培った実装・解析の基盤の上に、本計画では予測・予防へと研究を一段押し上げる準備が整っている。

研究計画の遂行と自身の強みの対応

本研究計画の各段階は、これまで培ってきた強みと直接対応している。研究 (1) の内部表現解析は、表現解析・部分空間計算・可視化の技能 [1][2] に裏打ちされる。研究 (2) の予測指標構築は、機械学習のモデリングと評価設計・汎化検証の経験 [3][4] に基づく。研究 (3) の予防的アルゴリズム設計は、理論的定式化と大規模実装を往復しながら手法を作り上げる力に支えられる。加えて、幾何学・神経科学といった異分野の知見を一つの課題へ統合してきた姿勢は、本計画の総合知的な性格と本質的に整合する。これらの対応関係は、申請者が本計画を主体的かつ着実に遂行しうることを示している。研究遂行上のリスクに対しても、予備的検討で得た知見と研究室の蓄積を活かし、計画の調整と代替経路の選択を自律的に行う準備がある。

(2) 今後研究者として更なる発展のため必要と考えている要素

要素 1：学際的知識の体系化——継続学習を機械学習・幾何・神経科学の交差点で捉えるには、各分野の知見を体系的に統合する力が不可欠である。これまで隣接分野を独学で広げてきたが、断片的な知識を原理として体系化する段階には至っていない。特別研究員の期間中は、神経科学の記憶研究や幾何的深層学習の文献講読・専門家との議論を通じてこの統合力を体系的に高め、分野横断的に新たな問いを立てられる研究者へと成長したい。

要素 2：国際的研究ネットワークと独立した研究推進力——国際会議での継続的な発表や海外研究者との共同を通じて分野横断的なネットワークを構築するとともに、研究構想の立案から資金獲得・成果公表までを一貫して主導できる**独立した研究者**としての基盤を築きたい。現状では国際的な共同研究を主導した経験が限られるため、特別研究員としての期間を、海外研究滞在や国際共著に挑戦してこれらの能力を集中的に養う機会と位置づけ、将来は本分野の研究を国際的に牽引する研究者を目指す。

以上の強みと今後伸ばすべき要素を踏まえると、特別研究員の期間に本研究計画を遂行することは、申請者が学術の将来を担う自立した研究者へと成長するうえで最良の機会であると確信している。獲得した内部表現・予測・予防の知見と研究遂行力を基盤に、継続学習の枠を越えて、知識の獲得と保持の問題に新たな原理を与える研究者へと発展していきたい。